# Вероятностный тензорный поезд как суррогатная модель для байесовской оптимизации

Артём Хапилов
Научный руководитель: Глеб Рыжаков
Код и данные: https://github.com/WeCanStart/ptt-bo

Черновик, ноябрь 2026

**Аннотация**

Исследуется задача байесовской оптимизации дорогой функции-чёрного ящика на гиперкубе при бюджете в 100–200 вычислений. Стандартная суррогатная модель — гауссовский процесс — требует $O(n^3)$ операций и в размерностях $d \geq 10$ нуждается в специальных приорах или локальных стратегиях. Предлагается суррогат в виде функционального тензорного поезда (TT) со случайными ядрами: ANOVA-приор, MAP-обучение и лапласовская аппроксимация апостериорного распределения дают прогноз и его неопределённость за время, линейное по числу наблюдений. В базовом эксперименте на 11 тестовых функциях ($d = 6$–$12$, 10 сидов) PTT-EI лучше всех сравниваемых методов после 40 вычислений, включая BoTorch LogEI и TuRBO-1, но затем перестаёт улучшаться. Показано, что выигрыш не связан с малым TT-рангом целевой функции, а определяется ANOVA-приором; застревание устраняется локальной моделью в доверительной области (TR-PTT). На девяти отложенных задачах ($d = 10$–$20$) с заранее зафиксированным протоколом TR-PTT значимо превосходит TuRBO-1 (75 из 90 пар, $p = 2 \cdot 10^{-10}$).

**Ключевые слова:** байесовская оптимизация, тензорный поезд, суррогатная модель, аппроксимация Лапласа, доверительная область.

## 1. Введение

**Проблема.** Во многих прикладных задачах — подборе гиперпараметров, настройке физических экспериментов, поиске молекулярных конфигураций — нужно найти минимум функции $f : \mathcal{X} \to \mathbb{R}$, одно вычисление которой стоит минуты или часы, а градиент недоступен. Байесовская оптимизация (BO) решает такую задачу, строя по уже вычисленным точкам вероятностную суррогатную модель и выбирая следующую точку максимизацией функции приобретения [1–4]. Качество BO определяется тем, насколько хорошо суррогат описывает $f$ и свою неуверенность при малом числе наблюдений.

**Краткий обзор.** Стандартный суррогат — гауссовский процесс (GP) [5] с ожидаемым улучшением (EI) [1] или верхней доверительной границей [6]. Современные реализации (BoTorch [7], LogEI [8]) и приоры на длины корреляции, масштабированные с размерностью [9], сделали «обычную» GP-BO конкурентной вплоть до сотен переменных. Для высоких размерностей предложены аддитивные модели [10, 11], разреженные подпространства [12], локальная оптимизация в доверительной области TuRBO [13] и преобразования выхода [14]. Независимо развивается аппарат тензорных поездов (TT) [15–17]: TT-крест [18], конструктивные TT-представления [19] и TT-оптимизаторы TTOpt [20] и PROTES [21], в том числе для глобальной оптимизации атомных кластеров [22]. TT-модели применяются и для регрессии — «экспоненциальные машины» [23], тензорные сети в обучении с учителем [24], TT-ядровые машины с признаками Фурье [25, 26] и TT-параметризация индуцирующих точек GP [27]; тензорная факторизация с ядрами использовалась как суррогат BO на сетке [28].

**Ограничения существующих методов** сведены в табл. 1. GP-суррогаты дают калиброванную неопределённость, но их обучение стоит $O(n^3)$, а глобальная модель с общими длинами корреляции плохо описывает неоднородные функции; TuRBO решает это локальностью, но медленно стартует. TT-оптимизаторы используют низкоранговую структуру, однако рассчитаны на тысячи вычислений и не

**Таблица 1:** Альтернативные подходы к суррогатной модели в BO

| Метод | Сильные стороны | Слабые стороны |
|---|---|---|
| GP-EI [1, 2] | калиброванная неопределённость, эффективность при малом $n$ | $O(n^3)$, подбор гиперпараметров, деградация при $d \gtrsim 10$ без приоров |
| GP с приорами, LogEI [7–9] | сильный метод «по умолчанию» в высоких размерностях | глобальная модель, $O(n^3)$ |
| Аддитивный GP [10, 11] | масштабируется по $d$ | не видит взаимодействий переменных |
| TuRBO [13] | локальность, устойчив к неоднородности $f$ | медленный старт на малых бюджетах |
| SAASBO [12] | отбор значимых переменных | дорогой MCMC, предполагает мало значимых осей |
| TT-cross, TTOpt, PROTES [18, 20, 21] | используют низкоранговую структуру, дешёвые шаги | нужны тысячи вычислений, нет неопределённости |
| TT-регрессия [23, 25, 27] | линейна по $n$, масштабируется по $d$ | не применялась в BO, нет калибровки дисперсии |

дают неопределённости. TT-регрессоры масштабируются по $n$ и $d$, но в BO почти не применялись: для этого нужна согласованная с данными апостериорная дисперсия.

**Предложение.** В работе предложен суррогат для BO в виде вероятностного функционального тензорного поезда (PTT): ядра поезда — случайные матричнозначные функции одной переменной в базисе Фурье; ANOVA-приор делает модель в пределе нулевой сложности константой с малыми поправками по одной и по паре переменных; апостериорное распределение аппроксимируется по Лапласу. Иначе говоря, *предложен метод для байесовской оптимизации дорогих функций, дающий прогноз с неопределённостью за линейное по $n$ время и отличающийся тензорной структурой суррогата вместо ядра GP*.

**Вклад.** (1) Сформулирована модель PTT для BO и выведены точные моменты прогноза при независимых ядрах. (2) В базовом эксперименте PTT-EI сравнен с GP-EI, аддитивным GP, BoTorch LogEI, TuRBO-1 и CMA-ES [29]: PTT-EI лучше всех на малых бюджетах, но затем застревает. (3) Показано, что выигрыш не связан с TT-рангом целевой функции; застревание устраняется локальной моделью в доверительной области (TR-PTT). (4) TR-PTT проверен на отложенных задачах по протоколу, записанному до запуска.

**Цель эксперимента.** Проверить, даёт ли PTT-суррогат меньший простой регрет, чем GP-суррогаты и неградиентные методы, при одинаковом бюджете вычислений на стандартных тестовых функциях с известным минимумом, и выяснить, от каких свойств задачи и модели зависит результат.

## 2. Постановка задачи

**Общее описание.** Мы решаем задачу минимизации дорогой функции: дан чёрный ящик $f$ на гиперкубе и бюджет из $N$ вычислений; требуется выбрать точки $\mathbf{x}_1, \ldots, \mathbf{x}_N$ так, чтобы лучшее найденное значение было как можно ближе к минимуму; качество измеряется простым регретом. Исследовательский вопрос — какой класс суррогатных моделей (GP или PTT) даёт меньший регрет при одинаковой стратегии выбора точек.

**Данные.** Объекты — точки $\mathbf{x} \in \mathcal{X} = [0,1]^d$ (каждая тестовая функция линейно отображена со своей стандартной области), целевая переменная — $y \in \mathbb{R}$. На шаге $t$ доступна выборка $\mathfrak{D}_t = \{(\mathbf{x}_i, y_i)\}_{i=1}^t$, где $y_i = f(\mathbf{x}_i) + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \beta^{-1})$ независимы (в незашумлённой постановке $\varepsilon_i$ играет роль регуляризатора). Первые $n_0$ точек — квазислучайная последовательность Соболя, остальные выбираются алгоритмом.

**Модель.** Суррогат — функциональный тензорный поезд

$$g(\mathbf{x}; \mathbf{W}) = \mathbf{G}_1(x_1)\, \mathbf{G}_2(x_2) \cdots \mathbf{G}_d(x_d), \qquad \mathbf{G}_k(x) = \sum_{j=1}^{m} \mathbf{W}_k[:, j, :]\, \phi_j(x) \in \mathbb{R}^{r_{k-1} \times r_k}, \tag{1}$$

$r_0 = r_d = 1$, $r_k = r$ при $0 < k < d$. Базис $\{\phi_j\}_{j=1}^{m}$, $m = 2n_f + 1$: константа и функции $\sqrt{\lambda_\omega}\cos(\pi\omega x)$, $\sqrt{\lambda_\omega}\sin(\pi\omega x)$, $\omega = 1, \dots, n_f$, с весами $\lambda_\omega \propto \exp\!\left(-\tfrac{1}{2}(\pi\omega\ell)^2\right)$ спектральной плотности квадратично-экспоненциального ядра [30]. Параметры $\mathbf{W} = (\mathbf{W}_1, \dots, \mathbf{W}_d)$, $\mathbf{W}_k \in \mathbb{R}^{r_{k-1}\times m\times r_k}$. Приор: $\mathbf{W}_k \sim \mathcal{N}(\mathbf{W}_k^0, \mathbf{V}_k)$ независимо по $k$; в ANOVA-приоре среднее $\mathbf{W}_k^0$ — единичная матрица при константной базисной функции, так что априорное среднее $g$ равно константе, а каждое ядро вносит малую поправку. Класс моделей $\mathfrak{G}_{\text{PTT}} = \{g(\cdot;\mathbf{W})\}$ при фиксированных $(r, n_f, \ell)$; при нулевом приоре ковариационная функция модели — произведение одномерных ядер, а при $r \to \infty$ модель сходится к GP с этим ядром.

**Внутренний критерий.** Параметры находятся как MAP-оценка

$$\hat{\mathbf{W}} = \arg\min_{\mathbf{W}} \mathcal{L}(\mathbf{W}), \qquad \mathcal{L}(\mathbf{W}) = \frac{\beta}{2}\sum_{i=1}^{t}\big(y_i - g(\mathbf{x}_i;\mathbf{W})\big)^2 + \frac{1}{2}\sum_{k=1}^{d}\|\mathbf{W}_k - \mathbf{W}_k^0\|^2_{\mathbf{V}_k^{-1}}, \tag{2}$$

точность шума $\beta$ выбирается трёхкратной кросс-валидацией на сетке $\mathcal{B} = \{1, 3, 10, \dots, 1000\}$. Апостериорное распределение аппроксимируется по Лапласу с матрицей Гаусса–Ньютона [31]: $q(\mathbf{w}) = \mathcal{N}(\hat{\mathbf{w}}, \boldsymbol{\Sigma})$, $\boldsymbol{\Sigma} = (\beta\mathbf{J}^\top\mathbf{J} + \mathbf{V}^{-1})^{-1}$, где $\mathbf{w} = \operatorname{vec}\mathbf{W}$, $\mathbf{J}$ — якобиан $g(\mathbf{x}_i;\mathbf{w})$ по $\mathbf{w}$ в точке $\hat{\mathbf{w}}$. Прогноз: $\mu_t(\mathbf{x}) = g(\mathbf{x};\hat{\mathbf{W}})$, $\sigma_t^2(\mathbf{x}) = \mathbf{j}(\mathbf{x})^\top\boldsymbol{\Sigma}\,\mathbf{j}(\mathbf{x})$.

**Алгоритм.** Следующая точка максимизирует ожидаемое улучшение

$$\mathbf{x}_{t+1} = \arg\max_{\mathbf{x}\in\mathcal{X}} \mathrm{EI}_t(\mathbf{x}), \qquad \mathrm{EI}_t(\mathbf{x}) = (y_t^* - \mu_t)\,\Phi(z) + \sigma_t\,\varphi(z), \quad z = \frac{y_t^* - \mu_t(\mathbf{x})}{\sigma_t(\mathbf{x})}, \tag{3}$$

$y_t^* = \min_{i\le t} y_i$. Метод = модель (1) + критерий (2) + алгоритм (3). В варианте TR-PTT максимум (3) ищется в доверительной области $\mathcal{T}_t = [\mathbf{c}_t - L_t/2,\ \mathbf{c}_t + L_t/2] \cap \mathcal{X}$ вокруг лучшей точки $\mathbf{c}_t$, модель обучается только на точках удвоенной области, отображённой в $[0,1]^d$, а $L_t$ меняется по правилам TuRBO-1 [13].

**Внешний критерий.** Простой регрет после $N$ вычислений $r_N = \min_{i\le N} f(\mathbf{x}_i) - f^*$, $f^* = \min_{\mathcal{X}} f$ известен для всех тестовых функций. Для сравнения по набору задач $\mathcal{F}$ и сидам $s$ используется

$$S_N(\mathfrak{a}) = \mathrm{IQM}_{f\in\mathcal{F},\,s}\ \log_{10}\frac{r_N(\mathfrak{a};f,s)}{\mathrm{median}_s\, r_N(\text{random};f,s)}, \tag{4}$$

межквартильное среднее нормированного логарифма регрета (0 — уровень случайного поиска, $-1$ — регрет в 10 раз меньше), с 95% стратифицированным бутстреп-интервалом [32] и парным тестом Уилкоксона по сидам.

**Задача исследования.** Среди методов $\mathfrak{A}$ (одинаковые $n_0$, $N$, сиды и функция приобретения там, где это применимо) найти

$$\mathfrak{a}^* = \arg\min_{\mathfrak{a}\in\mathfrak{A}} S_N(\mathfrak{a}), \qquad \mathfrak{A} = \{\text{PTT-EI, TR-PTT-EI, GP-EI, LogEI, TuRBO-1, CMA-ES, random}\}, \tag{5}$$

при ограничениях $N \le 200$, $d \le 20$, один процессорный поток на прогон.

## 3. Вычислительный эксперимент

**Данные.** Используются синтетические тестовые функции с известным минимумом: правильный ответ известен заранее, что позволяет измерять регрет точно. Базовый набор E9 (11 задач, $d = 6$–$12$): Hartmann6; Rosenbrock10, Dixon-Price10, Powell12, Zakharov10, Styblinski–Tang10; для части из них — повёрнутые случайной ортогональной матрицей ($f(Q(\mathbf{x}-\mathbf{c})+\mathbf{c})$) и переставленные версии, которые сохраняют ландшафт, но меняют TT-ранг (повороты используются по аналогии с COCO [33]). Отложенный набор E14 (9 задач, не использовавшихся при разработке TR-PTT): Levy, Levy с поворотом, Ackley, Griewank, Michalewicz, Rastrigin при $d = 10$ и Rosenbrock, Dixon-Price, Levy при $d = 20$.

**Конфигурация.** $n_0 = 20$, $N = 100$ (80 для Hartmann6) в E9 и $N = 150/200$ в E14; сиды 0–9 (сид фиксирует начальный план и все случайные решения метода). PTT: $r = 4$ ($r = 2$ при $d = 20$), $n_f = 5$, $\ell = 0.25$, ANOVA-приор, $\beta$ по кросс-валидации каждые 15 итераций, полный лапласовский прогноз;

**Таблица 2:** Обозначения (в последнем столбце — имя в коде `pttbo`)

| Обозначение | Смысл | В коде |
|---|---|---|
| $f,\ f^*$ | целевая функция и её минимум | `prob`, `prob.fopt` |
| $\mathcal{X} = [0,1]^d,\ d$ | область поиска и размерность | `prob.d` |
| $N,\ n_0$ | бюджет вычислений и число начальных точек | `budget`, `n_init` |
| $\mathfrak{D}_t = \{(\mathbf{x}_i, y_i)\}$ | выборка на шаге $t$ | `X`, `y` |
| $g(\mathbf{x};\mathbf{W}),\ \mathbf{G}_k,\ \mathbf{W}_k$ | PTT-модель, ядра, тензоры параметров | `PTT`, `W` |
| $r$ | TT-ранг | `rank` |
| $\phi_j,\ n_f,\ \ell$ | базис Фурье, число частот, длина корреляции | `FourierBasis(nf, ell)` |
| $\mathbf{W}_k^0,\ \mathbf{V}_k$ | среднее и дисперсия приора | `W0`, `v0` |
| $\beta$ | точность шума наблюдений | `beta` |
| $\mu_t,\ \sigma_t$ | прогноз и его стандартное отклонение | `predict` |
| $\mathrm{EI}_t$ | ожидаемое улучшение | `ei_min` |
| $\mathcal{T}_t,\ L_t$ | доверительная область и её сторона | `TrustRegion.L` |
| $r_N,\ S_N$ | простой регрет, сводная оценка | `stats_bo.py` |

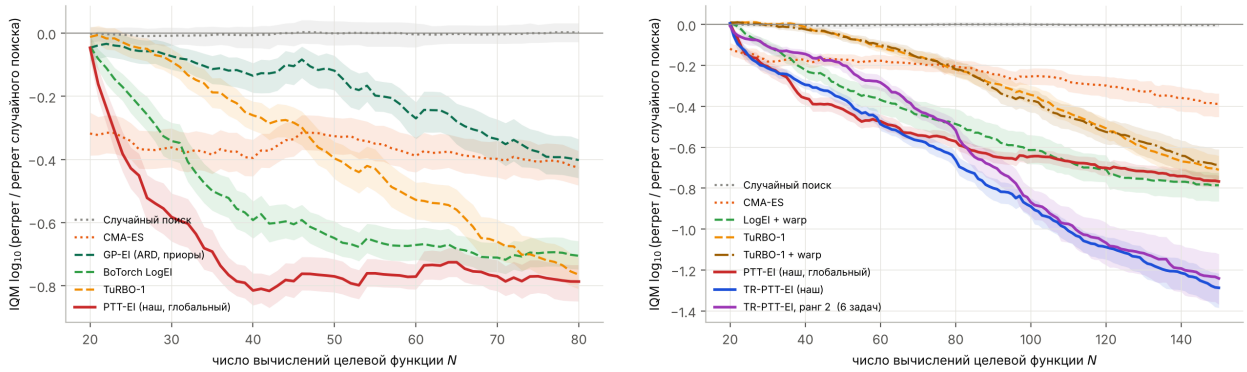



**Рис. 1:** Сводная оценка $S_N$ (4) в зависимости от числа вычислений $N$ (меньше — лучше, полоса — 95% бутстреп-интервал). Слева: базовый эксперимент E9 (11 задач, $d = 6$–$12$). Справа: отложенные задачи E14 (9 задач, $d = 10$–$20$).

(3) максимизируется по 2000 кандидатам с двумя раундами локального уточнения. Конкуренты: GP-EI с ARD-ядром и приорами длин корреляции [9]; аддитивный GP-EI; BoTorch LogEI [8]; TuRBO-1 по эталонной реализации BoTorch [7, 13]; CMA-ES; случайный поиск (базовый алгоритм). Все прогоны — один поток; полная конфигурация — в репозитории.

**План.** (1) Базовый эксперимент E9: PTT-EI против конкурентов. (2) Анализ свойств: абляции ранга, длины базиса и приора (E10), связь с TT-рангом функции (E3), причина застревания (E13). (3) Проверка улучшенного метода TR-PTT на отложенных задачах (E14) по протоколу, записанному до запуска: гипотезы H1 — TR-PTT лучше TuRBO-1 в конце бюджета, H2 — лучше TuRBO-1 с преобразованием выхода, H3 — лучше TuRBO-1 после 40 вычислений.

**Результаты базового эксперимента.** На рис. 1 (слева) видно, что кривая PTT-EI опускается быстрее всех: после 40 вычислений она лучше всех методов и лучше по медиане на 10 из 11 задач (табл. 3); против TuRBO-1 PTT-EI выигрывает в 90 из 110 пар (задача, сид). Однако после 40 вычислений доля шагов, улучшающих лучшее значение, падает с 17% до 5%, и к $N = 100$ TuRBO-1 выходит вперёд. PTT-EI значимо лучше нашего GP-EI с приорами (99 из 110 пар на $N = 40$, 75 из 100 на $N = 100$).

**Непротиворечивость.** Исходная гипотеза «PTT выигрывает за счёт малого TT-ранга целевой функции» не подтвердилась: поворот делает TT-ранг Rosenbrock10 и Dixon-Price10 равным 21 (вместо 3), но регрет PTT-EI почти не меняется, а ранговая корреляция выигрыша с рангом функции близка к нулю (Спирмен, $\rho \approx 0$). Абляции E10 показывают, что ранг $2/4/8$ и длина $\ell$ почти не влияют на результат, а замена ANOVA-приора на нулевой увеличивает регрет в 2–4 раза. Значит, выигрыш даёт ANOVA-приор: модель в первую очередь описывает одноперемменные и парные эффекты, что полезно

**Таблица 3:** Базовый эксперимент E9: $S_N$ и 95% интервал (11 задач $\times$ 10 сидов)

| Метод | $N = 40$ | $N = 100$ |
|---|---|---|
| PTT-EI (предлагаемый) | $\mathbf{-0.82}$ $[-0.87, -0.77]$ | $-0.86$ $[-0.92, -0.81]$ |
| BoTorch LogEI | $-0.59$ $[-0.66, -0.53]$ | $-0.80$ $[-0.85, -0.76]$ |
| TuRBO-1 | $-0.26$ $[-0.31, -0.21]$ | $\mathbf{-0.98}$ $[-1.05, -0.91]$ |
| Аддитивный GP-EI | $-0.25$ $[-0.31, -0.19]$ | $-0.61$ $[-0.66, -0.55]$ |
| GP-EI (ARD, приоры) | $-0.14$ $[-0.19, -0.09]$ | $-0.56$ $[-0.60, -0.51]$ |
| CMA-ES | $-0.40$ $[-0.46, -0.34]$ | $-0.49$ $[-0.55, -0.43]$ |
| Случайный поиск | 0.00 | 0.00 |

при малой выборке.

**Улучшение и проверка на отложенных задачах.** Эксперимент E13 (схема $2 \times 2$: глобальная или локальная модель, исходный или преобразованный выход [14]) показал, что застревание устраняет именно локальная модель в доверительной области; преобразование выхода поверх неё не помогает. На отложенных задачах (рис. 1, справа) TR-PTT-EI достигает $S_N = -1.39$ $[-1.49, -1.30]$ против $-0.80$ у TuRBO-1, $-0.77$ у TuRBO-1 с преобразованием выхода и $-0.82$ у LogEI с преобразованием выхода. Все три гипотезы протокола подтверждены парным тестом Уилкоксона по 90 парам: H1 — 75:15, $p = 2 \cdot 10^{-10}$; H2 — 71:19, $p = 2 \cdot 10^{-9}$; H3 — 81:9, $p = 2 \cdot 10^{-14}$. Вариант TR-PTT лучший по медиане на всех 9 задачах. Ограничения: синтетические функции, $d \leq 20$, $N \leq 200$; при $d = 10$ один прогон TR-PTT в 1.7–3.6 раза дороже TuRBO-1 по времени; на Hartmann6 лучшим остаётся TuRBO-1.

## 4. Заключение

Вероятностный тензорный поезд с ANOVA-приором и лапласовской неопределённостью оказался эффективным суррогатом для BO на малых бюджетах, а его локальная версия TR-PTT превзошла TuRBO-1 и LogEI на отложенных задачах размерности 10–20. Дальнейшие шаги: реальные задачи (подбор гиперпараметров, оптимизация молекулярных и кластерных конфигураций [22]), размерности $d \geq 50$, дискретные и смешанные переменные (где естественны TT-методы [19, 21]), ускорение лапласовского прогноза.

## Список литературы


[1] Donald R. Jones, Matthias Schonlau, and William J. Welch. Efficient global optimization of expensive black-box functions. *Journal of Global Optimization*, 13(4):455–492, 1998.

[2] Jasper Snoek, Hugo Larochelle, and Ryan P. Adams. Practical Bayesian optimization of machine learning algorithms. In *Advances in Neural Information Processing Systems 25 (NeurIPS)*, 2012. arXiv:1206.2944.

[3] Peter I. Frazier. A tutorial on Bayesian optimization, 2018. arXiv:1807.02811.

[4] Roman Garnett. *Bayesian Optimization*. Cambridge University Press, 2023.

[5] Carl Edward Rasmussen and Christopher K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.

[6] Niranjan Srinivas, Andreas Krause, Sham M. Kakade, and Matthias Seeger. Information-theoretic regret bounds for Gaussian process optimization in the bandit setting. *IEEE Transactions on Information Theory*, 58(5):3250–3265, 2012. Conference version: ICML 2010, arXiv:0912.3995.

[7] Maximilian Balandat, Brian Karrer, Daniel R. Jiang, Samuel Daulton, Benjamin Letham, Andrew Gordon Wilson, and Eytan Bakshy. BoTorch: A framework for efficient Monte-Carlo Bayesian optimization. In *Advances in Neural Information Processing Systems 33 (NeurIPS)*, 2020. arXiv:1910.06403.

[8] Sebastian Ament, Samuel Daulton, David Eriksson, Maximilian Balandat, and Eytan Bakshy. Unexpected improvements to expected improvement for Bayesian optimization. In *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. arXiv:2310.20708.

[9] Carl Hvarfner, Erik Orm Hellsten, and Luigi Nardi. Vanilla Bayesian optimization performs great in high dimensions. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2402.02229.

[10] David Duvenaud, Hannes Nickisch, and Carl Edward Rasmussen. Additive Gaussian processes. In *Advances in Neural Information Processing Systems 24 (NeurIPS)*, 2011. arXiv:1112.4394.

[11] Kirthevasan Kandasamy, Jeff Schneider, and Barnabás Póczos. High dimensional Bayesian optimisation and bandits via additive models. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015. arXiv:1503.01673.

[12] David Eriksson and Martin Jankowiak. High-dimensional Bayesian optimization with sparse axis-aligned subspaces. In *Proceedings of the 37th Conference on Uncertainty in Artificial Intelligence (UAI)*, 2021. arXiv:2103.00349.

[13] David Eriksson, Michael Pearce, Jacob R. Gardner, Ryan Turner, and Matthias Poloczek. Scalable global optimization via local Bayesian optimization. In *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019. arXiv:1910.01739.

[14] Alexander I. Cowen-Rivers, Wenlong Lyu, Rasul Tutunov, Zhi Wang, Antoine Grosnit, Ryan Rhys Griffiths, Alexandre Max Maraval, Hao Jianye, Jun Wang, Jan Peters, and Haitham Bou Ammar. HEBO: Pushing the limits of sample-efficient hyperparameter optimisation. *Journal of Artificial Intelligence Research*, 74, 2022. arXiv:2012.03826.

[15] Ivan V. Oseledets. Tensor-train decomposition. *SIAM Journal on Scientific Computing*, 33(5):2295–2317, 2011.

[16] Andrzej Cichocki, Namgil Lee, Ivan Oseledets, Anh-Huy Phan, Qibin Zhao, and Danilo P. Mandic. Tensor networks for dimensionality reduction and large-scale optimization: Part 1 low-rank tensor decompositions. *Foundations and Trends in Machine Learning*, 9(4-5):249–429, 2016. arXiv:1609.00893.

[17] Andrzej Cichocki, Anh-Huy Phan, Qibin Zhao, Namgil Lee, Ivan Oseledets, Masashi Sugiyama, and Danilo P. Mandic. Tensor networks for dimensionality reduction and large-scale optimization: Part 2 applications and future perspectives. *Foundations and Trends in Machine Learning*, 9(6):431–673, 2017. arXiv:1708.09165.

[18] Ivan Oseledets and Eugene Tyrtyshnikov. TT-cross approximation for multidimensional arrays. *Linear Algebra and its Applications*, 432(1):70–88, 2010.

[19] Gleb Ryzhakov and Ivan Oseledets. Constructive TT-representation of the tensors given as index interaction functions with applications. In *The Eleventh International Conference on Learning Representations (ICLR)*, 2023. arXiv:2206.03832.

[20] Konstantin Sozykin, Andrei Chertkov, Roman Schutski, Anh-Huy Phan, Andrzej Cichocki, and Ivan Oseledets. TTOpt: A maximum volume quantized tensor train-based optimization and its application to reinforcement learning. In *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 2022. arXiv:2205.00293.

[21] Anastasia Batsheva, Andrei Chertkov, Gleb Ryzhakov, and Ivan Oseledets. PROTES: Probabilistic optimization with tensor sampling. In *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. arXiv:2301.12162.

[22] Konstantin Sozykin, Nikita Rybin, Andrei Chertkov, Anh-Huy Phan, Ivan Oseledets, Alexander Shapeev, Ivan Novikov, and Gleb Ryzhakov. Global optimization of atomic clusters via physically-constrained tensor train decomposition, 2026. arXiv:2601.18592.

[23] Alexander Novikov, Mikhail Trofimov, and Ivan Oseledets. Exponential machines, 2016. arXiv:1605.03795.

[24] E. Miles Stoudenmire and David J. Schwab. Supervised learning with tensor networks. In *Advances in Neural Information Processing Systems 29 (NeurIPS)*, 2016. arXiv:1605.05775.

[25] Frederiek Wesel and Kim Batselier. Large-scale learning with Fourier features and tensor decompositions. In *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 2021. arXiv:2109.01545.

[26] Frederiek Wesel and Kim Batselier. Tensor network-constrained kernel machines as Gaussian processes. In *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics (AISTATS), PMLR 258*, 2025.

[27] Pavel Izmailov, Alexander Novikov, and Dmitry Kropotov. Scalable Gaussian processes with billions of inducing inputs via tensor train decomposition. In *Proceedings of the 21st International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2018. arXiv:1710.07324.

[28] Mengying Lei and Lijun Sun. Bayesian kernelized tensor factorization as surrogate for Bayesian optimization, 2023. arXiv:2302.14510.

[29] Nikolaus Hansen. The CMA evolution strategy: A tutorial, 2016. arXiv:1604.00772.

[30] Arno Solin and Simo Särkkä. Hilbert space methods for reduced-rank Gaussian process regression. *Statistics and Computing*, 30:419–446, 2020.

[31] Erik Daxberger, Agustinus Kristiadi, Alexander Immer, Runa Eschenhagen, Matthias Bauer, and Philipp Hennig. Laplace redux – effortless Bayesian deep learning. In *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 2021. arXiv:2106.14806.

[32] Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron Courville, and Marc G. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. In *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 2021. arXiv:2108.13264.

[33] Nikolaus Hansen, Anne Auger, Raymond Ros, Olaf Mersmann, Tea Tušar, and Dimo Brockhoff. COCO: A platform for comparing continuous optimizers in a black-box setting. *Optimization Methods and Software*, 36(1):114–144, 2021.